



Centro Universitário Álvares Penteado

Projeto Interdisciplinar: Ciência de Dados

1ª Entrega PI: Identificação de fontes, preparação (limpeza, derivação e integração) e análise descritiva completa da base financeira da CTI Global. Inclui medidas de posição e dispersão, representações gráficas e segmentação de cenários por desempenho.

Objetivo: Preparar e compreender a base de dados da CTI, identificando padrões, riscos e qualidade antes de análises mais complexas. Fornecer indicadores e uma base íntegra para subsidiar o dashboard da Entrega 2

Nomes:

Felipe Lázaro Mathey | Ra: 25027786
Gabriel Vazquez Mamede Diniz | Ra: 25027858
Gian Carlos Lemes Vieira | Ra: 25027511
Leticia Rodrigues da Silva | Ra: 25027748
Said Sales de Sousa | Ra: 25027606

Curso: Projeto
Interdisciplinar:
Ciência de Dados
-
Prof Eduardo
Savino Gomes

Turma:
CCOMP 4 -
Noturno

1. Objetivo

Este documento apresenta a Entrega 1 da matéria de Projeto Interdisciplinar de Ciência de Dados, referente à base de dados financeiros disponibilizada pela empresa parceira CTI Global. O objetivo desta etapa é identificar a fonte de dados, coletar e perfilar a base, selecionar, limpar, uniformizar, derivar, integrar e formatar os dados, e realizar uma análise descritiva completa (medidas de posição e dispersão, além de representações gráficas) que permita compreender o comportamento geral, a distribuição, a variabilidade e possíveis valores atípicos antes das análises mais complexas (inferencial e de regressão), previstas na Entrega 2.

2. Identificação e Catálogo de Fontes de Dados

Campo	Descrição
Fonte	CTI Global
Arquivo	Demonstrativo_Fecap_v3.csv
Data de disponibilização	Agosto/2026
Tipo de fonte	Única
Formato	CSV, separador ";", codificação Latin-1 (ISO-8859-1), decimal com vírgula
Volume	1.002.000 linhas x 4 colunas
Granularidade	Uma linha por combinação de Ano x Cenário x Conta contábil
Período coberto	12 anos (Ano 1 a Ano 12). Projeção/simulação financeira, não série histórica real
Campos disponíveis	Ano (categórico); Cenário (categórico, 1.200 cenários simulados por ano); Conta (categórico, ~69 contas de Balanço, DRE e Fluxo de Caixa); Valor (numérico, R\$)
Responsável pela coleta	Equipe do grupo, a partir do arquivo entregue pela CTI
Condições de uso	Nenhuma restrição adicional além das definidas no documento do Projeto Interdisciplinar (dados não publicáveis em repositório aberto sem

3. Coleta dos Dados Iniciais

A coleta foi realizada no ambiente Google Colab com leitura direta do arquivo CSV fornecido pela CTI. A base foi carregada e uma cópia foi preservada como camada “raw” (dados brutos), sem qualquer alteração, conforme exigido pelo escopo do projeto (separação entre dados brutos, em preparação e processados). Todas as transformações subsequentes foram aplicadas sobre cópias, nunca sobre a camada bruta original.

Link do ambiente Colab: https://colab.research.google.com/drive/1ROkn9CuL_Wtq95XKi3kEkhWTYFAz-YNK?usp=sharing

4. Perfil e Qualidade dos Dados

A etapa de perfilamento identificou a estrutura geral da base (1.002.000 linhas, sem duplicatas reais e sem valores nulos na coluna de valor) e revelou três informações relevantes de qualidade, tratados e documentados a seguir, em vez de corrigidos aleatoriamente.

4.1 Cobertura irregular de contas por ano

O número de linhas por combinação (ano, cenário) não é constante: os Anos 3 a 11 possuem 72 contas completas por cenário; os Anos 1 e 2 possuem 71 (falta a conta "BAL - Dividendos Antecipados", plausivelmente por ainda não haver lucro acumulado suficiente nesses anos iniciais); e o Ano 12 possui apenas 45 contas por cenário, faltando 27 contas de detalhe (Patrimônio Líquido e seus componentes, contas a receber/pagar detalhadas, entre outras). Decisão adotada: o Ano 12 foi mantido na análise das quatro contas-chave selecionadas — que estão presentes em todos os 12 anos — mas fica sinalizado (variável "ano_incompleto") para que não seja utilizado em indicadores que dependam das contas ausentes.

4.2 Linhas com contas não identificadas

Foram identificadas 43.200 linhas (4,31% da base) com o campo "Conta" vazio, associadas a valores numéricos pequenos (entre -0,03 e 0,03), possivelmente uma taxa (juros ou correção monetária). Decisão adotada: essas linhas foram isoladas em uma tabela de quarentena, à parte da base analítica principal, e não foram descartadas nem interpretadas sem confirmação. Ficam disponíveis para investigação futura junto à CTI ou aos professores orientadores.

4.3 Inversão de sinal no Passivo Circulante

A conta "BAL - Passivo Circulante" apresenta valores negativos em 100% dos cenários entre os Anos 1 e 4, positivos em praticamente todos os cenários entre os Anos 5 e 11 (menos de 1% de exceções), e uma divisão quase igual entre positivos e negativos no Ano 12 (50,4%). Por se tratar de um padrão sistemático por ano — e não de ruído aleatório entre cenários — o achado foi documentado como possível convenção de sinal do modelo financeiro da CTI, sem alteração dos valores originais. Nenhuma correção foi aplicada, evitando distorcer a informação original.

4.4 Validação de consistência contábil

Como verificação de qualidade, testou-se a relação contábil segundo a qual o Saldo Final de um período tende a corresponder ao Saldo Inicial do período seguinte, para o mesmo cenário. Em 13.200 pares comparados (todos os cenários, entre anos consecutivos), a diferença média e máxima observada foi de R\$ 0,00 em 100% dos casos, evidência forte de consistência interna da simulação para essas duas contas.

4.5 Convenção de sinal em DRE – Custos

A conta DRE - Custos apresenta valor negativo em 100% dos casos, em todos os anos e cenários da base. Diferentemente do Passivo Circulante (seção 4.3), aqui o padrão é constante e esperado, refletindo uma convenção de apresentação contábil em que os custos entram com sinal negativo para serem somados diretamente à Receita na composição do resultado. Provavelmente não se trata de uma inconsistência.

4.6 Ausência de variação em FLU - Distribuição para Acionista

Ao contrário das demais contas simuladas, a Distribuição para Acionista apresenta desvio-padrão igual a zero entre os 1.200 cenários em 10 dos 12 anos. Ou seja, todos os cenários recebem exatamente o mesmo valor de distribuição naquele ano. Pequena variação entre cenários aparece apenas nos Anos 4 e 12, provavelmente quando algum cenário atinge um limite de caixa disponível que restringe a distribuição planejada. Isso indica que essa conta é definida por política/planejamento da CTI, e não por simulação estocástica como as demais.

5. Seleção das Variáveis

Das 69 contas disponíveis na base de trabalho, foram selecionadas 10 contas-chave para aprofundamento:

- Liquidez e capital de giro: BAL - Ativo Circulante, BAL - Passivo Circulante;
- Fluxo de caixa: FLU - Saldo Inicial, FLU - Saldo Final, FLU - Investimentos, FLU - Distribuição para Acionista;
- Resultado e rentabilidade: DRE - Receita, DRE - Custos, DRE - EBITDA, DRE - Resultado Líquido.

Juntas, essas contas sustentam ao menos cinco indicadores financeiros (Capital de Giro Líquido, Liquidez Corrente, Margem Líquida, EBITDA e Variação de Caixa), atendendo ao requisito mínimo da Entrega 2. Todas as 10 contas estão presentes nos 12 anos da simulação, sem as lacunas identificadas na seção 4.1 para outras contas do balanço. A seleção original de 4 contas foi mantida como núcleo por coerência com a entrega da disciplina de Análise Inferencial de Dados, realizada anteriormente pelo mesmo grupo.

6. Limpeza e Padronização

As seguintes transformações de limpeza e padronização foram aplicadas sobre a base selecionada:

- Conversão do campo "Ano" (texto, ex.: "Ano 1") para um campo numérico ("ano"), permitindo ordenação e cálculo corretos;
- Padronização dos nomes das contas, removendo espaços duplicados observados na base original;
- Criação de uma variável indicadora ("ano_incompleto") para sinalizar o Ano 12 sem removê-lo da base;
- Preservação do sinal original do Passivo Circulante, sem correção (ver seção 4.3).

Não foram identificadas duplicatas genuínas nem valores nulos na coluna de valor para as 4 contas selecionadas. A única ausência de dados relevante já está descrita na seção 4.1.

7. Derivação e Integração

A base, originalmente em formato longo (uma linha por combinação de ano, cenário e conta), foi integrada em formato largo (uma linha por ano/cenário, com uma coluna por conta), permitindo o cálculo de indicadores que cruzam múltiplas contas. Foram derivados três indicadores financeiros:

Indicador	Formúla	Observação
Capital de Giro Líquido	Ativo Circulante – Passivo Circulante	Calculável para os 12 anos
Liquidez Corrente	Ativo Circulante / Passivo Circulante	Calculado apenas quando o Passivo Circulante é positivo (8.966 de 14.400 cenários); nos demais casos o indicador não é interpretável e foi marcado como ausente
Variação de Caixa	Saldo Final – Saldo Inicial	Calculável para os 12 anos
Margem Líquida	Resultado Líquido / Receita	Calculável para os 12 anos, sem valores ausentes

A decisão de não calcular a Liquidez Corrente quando o Passivo Circulante é negativo ou zero evita a geração de um índice sem significado financeiro (uma "liquidez negativa" não é interpretável), sendo registrada como limitação explícita da análise.

8. Formatação da Base Final e Dicionário de Dados

A base analítica final resultante do processo de preparação contém 14.400 linhas (12 anos x 1.200 cenários) e 10 colunas, salva em camada "processed", separada das camadas "raw" e "staging" (quarentena).

Campo	Tipo	Unidade	Fonte	Descrição
ano	inteiro	nº (1-12)	derivado	Ano da simulação; Ano 12 possui cobertura reduzida de contas
cenario	texto	-	original	Identificador do cenário simulado (1 a 1.200)
ano_incompleto	booleano	-	derivado	Verdadeiro quando ano = 12
regime	Texto	-	derivado	Classificação por padrão de sinal do Passivo Circulante (Anos 1-4, 5-11 ou 12)
BAL - Ativo Circulante	decimal	R\$	original	Bens e direitos conversíveis em caixa em até 12 meses
BAL - Passivo Circulante	decimal	R\$	original	Obrigações de curto prazo; sinal negativo predominante nos Anos 1-4 (achado documentado)
FLU - Saldo Inicial	decimal	R\$	original	Caixa disponível no início do período
FLU - Saldo Final	decimal	R\$	original	Caixa disponível no fim do período
FLU - Investimentos	decimal	R\$	original	Saída de caixa para investimentos no período (valor negativo)
FLU - Distribuição para Acionista	decimal	R\$	original	Distribuição de dividendos; fixa por ano em 10 dos 12 anos (seção 4.6)
DRE - Receita	decimal	R\$	original	Receita do período
DRE - Custos	decimal	R\$	original	Custos do período; negativo por convenção em 100% dos casos (seção 4.5)
DRE - EBITDA	decimal	R\$	original	Lucro antes de juros, impostos, depreciação e amortização
DRE - Resultado Líquido	decimal	R\$	original	Lucro líquido do período
capital_giro_liquido	decimal	R\$	derivado	Ativo Circulante – Passivo Circulante
liquidez_corrente	decimal	razão	derivado	Ativo Circulante / Passivo

				Circulante; ausente quando Passivo ≤ 0
variacao_caixa	decimal	R\$	derivado	Saldo Final – Saldo Inicial do mesmo período
margem_liquida	decimal	razão	derivado	Resultado Líquido / Receita


9. Análise Descritiva


A tabela a seguir apresenta as medidas de posição (média, mediana, moda) e de dispersão (desvio-padrão, variância), além de mínimo e máximo, para as quatro contas-chave. A moda foi calculada de duas formas: a moda literal (valor exato mais repetido) e a moda de classe (baseada nos intervalos do histograma). A moda literal tem pouca utilidade em dados contínuos simulados, onde a repetição exata de um valor é rara, por isso a moda de classe é a referência mais adequada para interpretação nesta análise.

Conta	Média	Median a	Moda (classe)	Desvio-padrão	Mínimo	Máximo
BAL - Ativo Circulante	1.520,2	1.599,1	937,1	777,5	-35,4	8.300,1
BAL - Passivo Circulante	1.170,2	1.291,9	2.509,9	2.004,2	-1.875,9	4.542,4
FLU - Saldo Inicial	1.163,6	1.071,0	416,6	827,8	0,1	8.329,1
FLU - Saldo Final	1.135,7	1.088,2	404,5	851,9	-12,6	8.329,1

Valores expressos em R\$ milhões, consolidando os 12 anos e 1.200 cenários por conta.

9.1 BAL - Ativo Circulante







Figuras – Boxplot e Histograma do Ativo Circulante

A distribuição apresenta multimodalidade, com concentração entre R\$ 0,8 e R\$ 1,0 bilhão e um segundo agrupamento entre R\$ 1,7 e R\$ 2,3 bilhões, que é um reflexo da consolidação de diferentes anos em um único conjunto de dados. A média (R\$ 1.520,2 milhões) é levemente inferior à mediana (R\$ 1.599,1 milhões), indicando leve assimetria à esquerda. O boxplot mostra grande quantidade de outliers acima de R\$ 4 bilhões, compatível com o alto número de cenários simulados. Não há valores negativos relevantes, o que bate com a natureza da conta.

9.2 BAL - Passivo Circulante





Figuras – Boxplot e Histograma do Passivo Circulante

É a conta de maior dispersão entre as quatro (desvio-padrão de R\$ 2.004,2 milhões) e a única cujo boxplot cruza o zero. A distribuição consolidada aparenta ser multimodal e de difícil interpretação isolada; porém, ao separar os dados por tipo de sinal, fica claro que a variabilidade decorre da combinação de três populações distintas dentro da mesma conta, e não porque os valores de cada ano estão muito espalhados.






Figura – Passivo Circulante segmentado por regime de sinal (Ano 12, Anos 1-5 e Ano 5-11)

Essa divisão confirma que a grande variação na conta acontece apenas porque juntamos vários anos. Quando

olhamos cada tipo de sinal separadamente, os valores variam muito menos do que o gráfico geral mostra. Essa é a principal lição aqui: analisar o Passivo Circulante sem separar por ano geraria uma conclusão totalmente errada.



9.3 FLU – Saldo Inicial



Figuras – Boxplot e Histograma do Saldo Inicial

Apresenta forte assimetria à direita, com concentração de cenários entre R\$ 0 e R\$ 2 bilhões e uma cauda longa de outliers que se estende até aproximadamente R\$ 8,3 bilhões. A média (R\$ 1.163,6 milhões) acima da mediana (R\$ 1.071,0 milhões) confirma essa assimetria.

9.4 FLU – Saldo Final



Figuras – Boxplot e Histograma do Saldo Final

Padrão muito semelhante ao do Saldo Inicial, com médias próximas (R\$ 1.135,7 milhões e R\$ 1.163,6 milhões, respectivamente) e mesma assimetria à direita. Essa proximidade é coerente com a relação contábil entre as duas contas — o Saldo Final de um período compõe o Saldo Inicial do período seguinte — validada na seção 4.4, com diferença de R\$ 0,00 em 100% dos 13.200 pares comparados.

9. 5 Contas Adicionais (Resultado, Rentabilidade e Fluxo de Caixa)

A análise descritiva das quatro contas originalmente utilizadas na disciplina de Análise Inferencial de Dados foi mantida por completude metodológica, servindo de base para a seleção ampliada desta entrega. A contribuição específica desta etapa está na ampliação para dez contas, incluindo indicadores de resultado e fluxo de caixa não explorados anteriormente, apresentados a seguir com o mesmo nível de detalhe.

Conta	Média	Mediana	Moda (classe)	Desvio-padrão	Mínimo	Máximo
FLU - Investimentos	-140,6	-76,8	-53,9	172,7	-961,6	-6,1
FLU - Distr. p/ Acionista	-3.434,8	-2.875,4	-2.249,8	2.101,3	-15.879,8	-1.532,4
DRE - Receita	7.913,4	7.337,0	6.782,7	1.668,4	5.751,6	14.589,6
DRE - Custos	-1.205,4	-1.215,7	-1.207,1	115,9	-1.454,5	-860,8
DRE - EBITDA	6.504,5	5.937,5	5.106,8	1.814,8	4.320,0	13.761,5
DRE - Resultado Líquido	3.356,6	2.978,9	2.421,3	1.332,7	1.653,5	8.234,4

Valores expressos em R\$ milhões, consolidando os 12 anos e 1.200 cenários por conta.




Figura – Histograma e Boxplot de Investimentos

Valores integralmente negativos (saída de caixa), com concentração próxima de zero e cauda estendendo-se até -R\$ 961,6 milhões nos cenários de maior investimento.




Figura – Histograma e Boxplot de Distribuição para Acionista

Distribuição concentrada em poucos valores discretos, refletindo o achado da seção 4.6: a variável é majoritariamente fixa por ano, e não aleatória.





Figura – Histograma e Boxplot da Receita

Distribuição aproximadamente simétrica, com leve assimetria à direita. Receita mínima de R\$ 5.751,6 milhões garante que a Margem Líquida seja sempre calculável, sem divisões por valores próximos de zero.



Figura– Histograma e Boxplot dos Custos

Distribuição concentrada e simétrica, inteiramente no campo negativo (ver seção 4.5). A baixa dispersão relativa (desvio-padrão de R\$ 115,9 milhões frente a uma média de -R\$ 1.205,4 milhões) indica que os custos variam pouco entre cenários, ao contrário da Receita.




Figura – Histograma e Boxplot do EBITDA

Segue o mesmo padrão de leve assimetria à direita da Receita, o que é esperado dado que o EBITDA deriva diretamente dela.




Figura – Histograma e Boxplot do Resultado Líquido

Distribuição assimétrica à direita, com todos os valores positivos (mínimo de R\$ 1.653,5 milhões) — nenhum cenário simulado resulta em prejuízo líquido em nenhum ano.

9.6 Contas Adicionais (Resultado, Rentabilidade e Fluxo de Caixa)

Além da análise por conta individual, os 1.200 cenários foram classificados por desempenho, usando o Resultado Líquido acumulado ao longo dos 12 anos como critério: Piores 10% (133 cenários), Medianos 10%-90% (947) e Melhores 10% (120).

A validação da estrutura de dados revelou um achado relevante sobre a natureza da simulação: cada "cenário" representa uma trajetória coerente ao longo do tempo, e não um sorteio independente a cada ano. O cenário Cen_01128 é o melhor em 11 dos 12 anos, e o cenário Cen_01089 é o pior nos 12 anos, sem exceção. A correlação do Resultado Líquido entre anos consecutivos, para o mesmo cenário, varia entre 0,945 e 0,998 — evidência de forte persistência temporal.




Figura – Distribuição do Resultado Líquido Acumulado, com cortes de percentil (P10/P90)

A distribuição concentra-se fortemente entre R\$ 40 e R\$ 41 bilhões, com poucos cenários dispersos nos extremos. Não há indício de cenários de ruptura (catastróficos) ou excepcionalmente atípicos na simulação.




Figura – Margem Líquida por grupo de desempenho

Comparando a Margem Líquida entre os grupos, observou-se que ela não difere de forma relevante (41,3% nos Melhores 10% vs. 39,4% nos Piores 10%, com distribuições sobrepostas). A Receita média anual também varia pouco entre extremos (aproximadamente 4,7%). Isso indica que o desempenho acumulado não é explicado por um único fator dominante, mas pela composição de pequenas variações anuais ao longo dos 12 anos.




Figura – Boxplot da Margem Líquida, Melhores 10%




Figura – Boxplot da Margem Líquida, Piores 10%




Figura – Histograma da Margem Líquida, Melhores 10%




Figura – Histograma da Margem Líquida, Piores 10%

Os histogramas revelam perfis quase idênticos entre os dois grupos, ambos bimodais, com pico principal entre 35% e 42% e um pico secundário entre 55% e 58%. Investigação adicional mostrou que esse segundo pico corresponde inteiramente ao Ano 12, cuja margem líquida média salta para 57,7%, descolada da tendência gradual observada do Ano 1 (36,2%) ao Ano 11 (47,9%). Esse padrão reforça a hipótese, já levantada na seção 4.1, de que o Ano 12 representa uma fase estruturalmente distinta do modelo (possivelmente de encerramento da concessão), e não deve ser tratado como continuidade direta da tendência dos demais anos em análises futuras.

10. Conclusão Preliminar e Limitações

A análise descritiva das quatro contas-chave selecionadas evidenciou distribuições predominantemente multimodais (Ativo e Passivo Circulante) ou assimétricas à direita (Saldo Inicial e Saldo Final), refletindo a agregação de diferentes anos e cenários simulados em um único conjunto de dados. O achado mais relevante desta etapa foi o padrão sistemático de inversão de sinal do Passivo Circulante ao longo dos anos, tratado como característica documentada do modelo financeiro da CTI, sem correção. A validação cruzada entre Saldo Final e Saldo Inicial (diferença nula em 100% dos casos) fornece evidência sólida de consistência interna da base.

Limitações identificadas: (i) o Ano 12 possui cobertura reduzida de contas, o que restringe a análise de indicadores que dependam de contas ausentes nesse ano, além de apresentar Margem Líquida estruturalmente

destoante dos demais anos; (ii) 43.200 linhas da base original (4,31%) não puderam ser associadas a uma conta identificada e foram isoladas para investigação futura; (iii) o indicador de Liquidez Corrente não pôde ser calculado para todos os cenários, dado que a divisão por um Passivo Circulante negativo ou nulo não é interpretável financeiramente.

A segmentação de cenários por desempenho acumulado revelou que nem a Margem Líquida nem a Receita, isoladamente, explicam de forma satisfatória a diferença entre os melhores e piores resultados simulados, ambas variam pouco entre os grupos extremos. Esse resultado reforça a necessidade de uma análise multivariada (regressão) na Entrega 2, capaz de investigar de forma conjunta quais variáveis efetivamente explicam o Resultado Líquido acumulado. As medidas de posição e dispersão, as representações gráficas e a segmentação por desempenho, em conjunto, fornecem uma base sólida e documentada para essa próxima etapa.